Jagoda Płócienniczak, Magdalena Ryś, Zuzanna Sosnowska, Paweł Stępień, Magdalena Sudół

Dokumentacja — projekt bazy danych

Czerwiec 2025

1. Spis użytych technologii:

1. Jupyter Notebook – użyty do połączenia skryptów generujących dane i wypełniających tabele oraz opisów poszczególnych tabel.
2. Python (wersja 3.12.1) – użyty do napisania skryptów. Wykorzystano następujące biblioteki:
   a) NumPy
   b) Pandas
   c) Collections
   d) Typing
   e) Datetime
3. R (wersja 4.4.1) – użyty do przeprowadzenia analizy danych. Wykorzystano następujące pakiety:
   a) RMariaDB
   b) Ggplot2
   c) Knitr
4. Quarto – użyty do połączenia skryptów w języku R oraz komentarzy zawierających treść raportu, a następnie wygenerowania gotowego raportu.
5. LaTeX – użyty do napisania dokumentacji.

2. Lista plików i opis ich zawartości:

1. StarWars.ipynb – plik Jupyter Notebook z podstawowymi informacjami o firmie, opisem warunków, z których korzystaliśmy przy wypełnianiu tabel danymi oraz skryptami napisanymi w języku Python, do generowania oraz wypełniania danymi bazy.
2. customer_names.csv – plik CSV, zawierający listę imion i nazwisk potencjalnych klientów, pobrany ze strony Kaggle.
3. StarWars.json.vuerd – schemat bazy danych ERD w formacie Vuerd.
4. Raport.qmd – plik Quarto z tekstem raportu oraz skryptami w języku R, służącymi do połączenia się z bazą danych oraz uzyskania wyników zapytań, a także do analizy otrzymanych wyników.
5. Raport.html – plik wynikowy, otrzymany po zrenderowaniu pliku Quarto, zawierający analizę danych z bazy.
6. styles.css – plik CSS, służący do określenia stylu dokumentu HTML (wyśrodkowanie podpisów do każdego wykresu).
7. Dokumentacja_bazy_danych.pdf - dokumentacja projektu w formacie PDF.

3. Kolejność i sposób uruchamiania kolejnych plików, aby uzyskać gotowy projekt:

W celu uruchomienia wszystkich plików, niezbędne jest posiadanie Pythona w wersji przynajmniej 3.11 oraz R w wersji 4.4.1. wraz z wymienionymi bibliotekami i pakietami, a także odpowiednie środowiska programistyczne. Niezbędna będzie także możliwość obsługi plików Jupyter Notebook oraz Quarto.

Kolejność uruchamiania plików:

1. W pierwszej kolejności należy otworzyć plik StarWars.ipynb. Uruchomienie wszystkich komórek opcją Run All pozwoli na połączenie się z bazą danych, następnie stworzenie odpowiednich tabel oraz wypełnienie ich danymi według określonych warunków.
2. Następnie należy otworzyć plik Raport.qmd, zawierający tekst raportu oraz komórki ze skryptem napisanym w języku R, służącym do połączenia z bazą danych oraz wykonania zdefiniowanych zapytań. Wykonanie opcji „Render" pozwoli na wywołanie każdej komórki kodu oraz uzyskanie wyników, a także stworzenie gotowego raportu w formacie HTML.
3. Po otworzeniu pliku Raport.html dostępny jest tekst raportu, wykonanego na podstawie analizy danych z bazy.

4. Schemat projektu bazy danych:

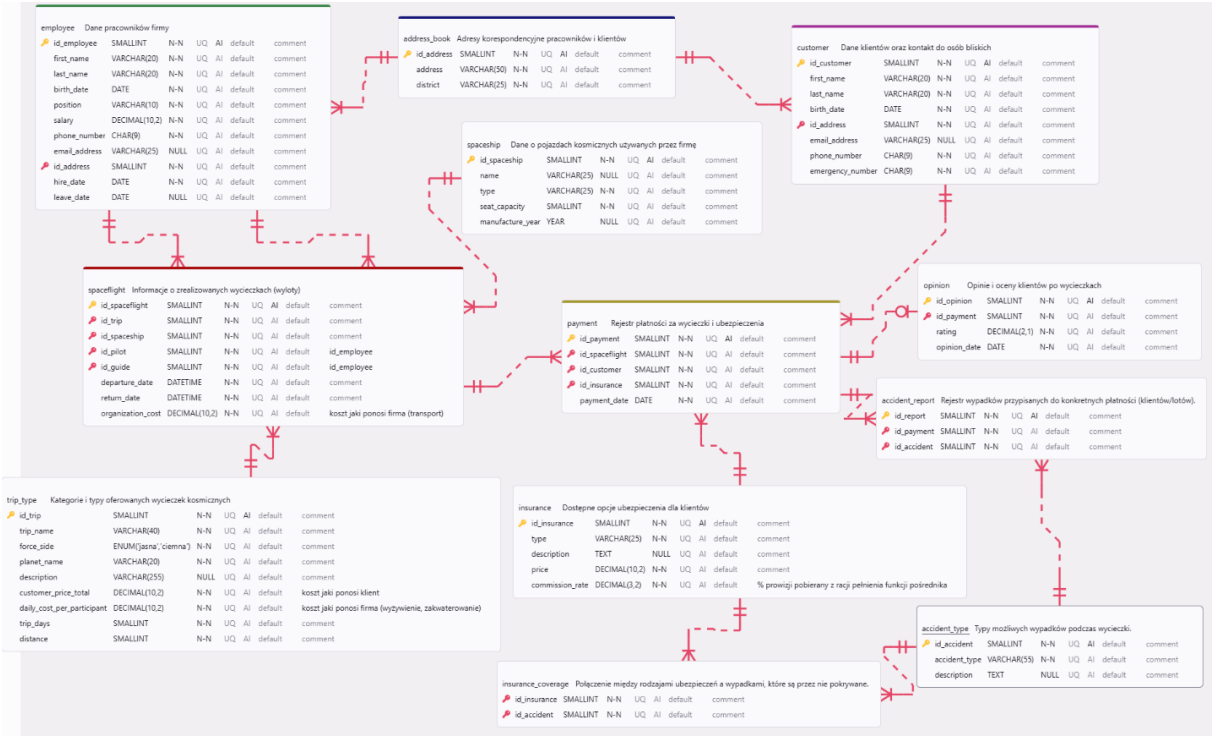

Rysunek 1. Schemat projektu bazy danych

5. Lista zależności funkcyjnych z wyjaśnieniem dla każdej relacji:

5.1. Lista zależności funkcyjnych w tabelach

1. **employee**: *id_employee* → *first_name, last_name, birth_date, position, salary, phone_number, email_address, id_address, hire_date, leave_date*
   id_employee – klucz główny, *id_address* – klucz obcy.
   Id pracownika wskazuje jednoznacznie na konkretną osobę, którą opisują imię, nazwisko, data urodzenia i inne dane personalne, a także data zatrudnienia i (ewentualnie) odejścia z firmy, zajmowane stanowisko i otrzymywana wypłata.
2. **address_book**: *id_address* → *address, district*
   id_address – klucz główny.
   Każdy adres ma przypisane w tabeli unikalne id.
3. **customer**: *id_customer* → *first_name, last_name, birth_date, id_address, email_address, phone_number, emergency_number*
   id_customer – klucz główny, *id_address* – klucz obcy.

Podobnie jak w przypadku tabeli **employee**, id klienta wskazuje jednoznacznie na konkretną osobę o określonych danych personalnych.

4. **spaceship**: *id_spaceship → name, type, seat_capacity, manufacture_year*
   id_spaceship – klucz główny.
   Każdy posiadany przez firmę pojazd kosmiczny charakteryzuje się pewną nazwą, typem, pojemnością i rokiem produkcji.
5. **spaceflight**: *id_spaceflight → id_trip, id_spaceship, id_pilot, id_guide, departure_date, return_date, organisation_cost*
   id_spaceflight – klucz główny, *id_trip, id_spaceship, id_pilot, id_guide* – klucze obce.
   Każdy wylot związany jest z pewną wycieczką, pojazdem, pilotem, przewodnikiem, datą wyjazdu oraz powrotu i kosztem organizacji.
6. **payment**: *id_payment → id_spaceflight, id_customer, id_insurance, payment_date*
   id_payment – klucz główny, *id_spaceflight, id_customer, id_insurance* – klucze obce.
   Każda płatność związana jest z określonym lotem, jest uiszczana przez pewną osobę, która wykupiła ubezpieczenie lub nie, oraz jest dokumentowana określonego dnia.
7. **trip_type**: *id_trip → trip_name, force_side, planet_name, description, customer_price_total, daily_cost_per_participant, trip_days, distance*
   id_trip – klucz główny.
   Każda wycieczka ma inny typ, przypisaną stronę mocy, nazwę planety i opis, wiąże się z określonymi kosztami, trwa pewną ilość dni, a w jej trakcie przebywana jest określona odległość.
8. **opinion**: *id_opinion → id_payment, rating, opinion_date*
   id_opinion – klucz główny, *id_payment* – klucz obcy.
   Określona opinia została wystawiona po danej wycieczce, wyraża pewną ocenę i została wystawiona konkretnego dnia.
9. **insurance**: *id_insurance → type, description, price*
   id_insurance – klucz główny.
   Każde ubezpieczenie ma przypisany typ, opis i cenę.
10. **insurance_coverage**: *id_accident, id_insurance*
    id_accident, id_insurance – klucze obce.
    Różne wypadki są przyporządkowane do różnych typów ubezpieczeń.
11. **accident_report**: *id_report → id_payment, id_accident*
    id_report – klucz główny, *id_payment, id_accident* – klucze obce.
    Każdy zgłoszony wypadek łączy się z osobą, która dokonała danej rezerwacji i uległa określonemu wypadkowi.
12. **accident_type**: *id_accident → accident_type, description*
    id_accident – klucz główny.
    Id wypadku wskazuje jednoznacznie na typ i opis wypadku.

5.2. Lista zależności pomiędzy tabelami

— **employee** i **spaceflight**: *employee.id_employee → spaceflight.id_pilot*
Relacja 1:N (jeden do wielu, pracownik może latać jako pilot na wiele wycieczek).
— **employee** i **spaceflight**: *employee.id_employee → spaceflight.id_guide*
Relacja 1:N (jeden do wielu, pracownik może latać jako przewodnik na wiele wycieczek).
— **address_book** i **employee**: *address_book.id_address → employee.id_address*
Relacja 1:N (jeden do wielu, jeden adres może być przypisany do wielu pracowników).
— **address_book** i **customer**: *address_book.id_address → customer.id_address*
Relacja 1:N (jeden do wielu, jeden adres może być przypisany do wielu klientów).
— **spaceship** i **spaceflight**: *spaceship.id_spaceship → spaceflight.id_spaceship*
Relacja 1:N (jeden do wielu, jeden statek odbył wiele lotów).
— **trip_type** i **spaceflight**: *trip_type.id_trip → spaceflight.id_trip*
Relacja 1:N (jeden do wielu, każdy typ wycieczki mógł odbyć się wielokrotnie).
— **spaceflight** i **payment**: *spaceflight.id_spaceflight → payment.id_spaceflight*
Relacja 1:N (jeden do wielu, na tą samą wycieczkę poleciało wiele osób).
— **customer** i **payment**: *customer.id_customer → payment.id_customer*
Relacja 1:N (jeden do wielu, jeden klient mógł wielokrotnie pojechać na wycieczkę).
— **payment** i **opinion**: *payment.id_payment → opinion.id_payment*
Relacja 0:1 (zero lub jeden, po każdej wycieczce można wystawić co najwyżej jedną opinię).

— **insurance** i **payment**: *insurance.id_insurance → payment.id_insurance*
Relacja 1:N (jeden do wielu, jeden typ ubezpieczenia mógł zostać wykupiony w wielu rezerwacjach).
— **insurance** i **insurance_coverage**:
insurance.id_insurance → insurance_coverage.id_insurance
Relacja 1:N (jeden do wielu, jeden typ ubezpieczenia pokrywa kilka wypadków).
— **accident_type** i **insurance_coverage**:
(insurance_coverage.id_insurance, insurance_coverage.id_accident)
Relacja N:M (wiele do wielu, jeden typ wypadku jest pokrywany przez wiele ubezpieczeń, jedno ubezpieczenie może obejmować wiele typów wypadków).
— **accident_type** i **accident_report**:
accident_type.id_accident → accident_report.id_accident
Relacja 1:N (jeden do wielu, każdy typ wypadku został zgłoszony wielokrotnie).
— **accident_type** i **accident_report**:
accident_type.id_accident → accident_report.id_accident
Relacja 1:N (jeden do wielu, każdy typ wypadku został zgłoszony w przypadku wielu rezerwacji).

6. Uzasadnienie, że baza jest w EKNF:

Baza jest w EKNF, ponieważ każda z komórek zawiera pojedynczą wartość i wszystkie rekordy są unikalne (baza spełnia wymogi 1NF), w tabelach nie ma częściowych zależności (baza spełnia wymogi 2NF) i nie zawierają one zależności przechodnich (spełniony wymóg 3 NF). Ponadto wartości w poszczególnych polach tabel zależą tylko od klucza głównego. W przypadku tabeli insurance_coverage klucz traktujemy jako parę – nie istnieje żadna tabela, która odwoływałaby się tylko do prawej lub lewej kolumny.
Dlatego baza danych jest w EKNF.

7. Opis, co było najtrudniejsze podczas realizacji projektu:

Najtrudniejsza w realizacji projektu była część związana z tworzeniem tabel, zwłaszcza w kwestii stworzenia spójnego systemu opłat za wycieczki (m.in. za zakwaterowanie czy paliwo) oraz stworzenie tabel z informacjami na temat ubezpieczeń tak, aby baza danych spełniała również wymogi EKNF. Część ta wymagała dobrego przemyślenia schematu bazy danych oraz warunków, branych pod uwagę przy wstawianiu wartości.